

VAN YÜZÜNCÜ YIL ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ DESTEKLİ SAĞLIK RİSK ANALİZİ

Machine Learning-Based Health Risk Analysis

LİSANS BİTİRME PROJESİ RAPORU

Muhammet Safa KAYA

Danışman: Dr. Öğr. Üyesi Emre BİÇEK

Van
Haziran, 2026

ÖZET

Günümüz sağlık sistemlerinde kronik hastalıkların erken teşhisi ve kişiselleştirilmiş risk değerlendirmesi, hasta yaşam kalitesinin artırılması ve sağlık maliyetlerinin düşürülmesi açısından kritik bir role sahiptir. Diyabet, kronik böbrek yetmezliği ve kardiyovasküler (CVD) patolojiler, tıp literatüründe Kardiyovasküler-Böbrek-Metabolik (CKM) sendromu olarak tanımlanan ve birbiriyle sıkı etkileşim halinde olan kronik süreçlerdir. Ancak geleneksel klinik analiz araçları genellikle tek bir hastalığa odaklanmakta, bu durum hastanın genel sağlık profilinin parçalı ve eksik değerlendirilmesine neden olmaktadır.

Bu projede; bireylere ait 5132 gözlemleri rutin biyokimyasal kan tahlili ve demografik verileri kullanılarak diyabet, böbrek yetmezliği ve kalp-damar hastalık risklerini eş zamanlı ve çoklu-çıkıtlı (multi-target) olarak tahmin eden yapay zeka destekli web tabanlı bir Klinik Karar Destek Sistemi (CDSS) geliştirilmiştir. Veri setinde doğrudan bulunmayan böbrek ve kalp riski etiketleri; uluslararası klinik yönetim kılavuzları olan KDIGO (CKD-EPI 2021 eGFR denklemi) ve AHA/ACC (Aterojenik Plazma İndeksi - AIP) standartlarına dayalı olarak geliştirilen şartlı sentetik etiketleme metodolojisi ile üretilmiştir.

Sınıflandırma modellerinde XGBoost, Random Forest ve Lojistik Regresyon algoritmaları eğitilmiş; tam entegre XGBoost işlem hattı (pipeline) ile Diyabet tahmininde %83.15 doğruluk (0.9114 ROC-AUC), Böbrek Riskinde %87.44 doğruluk (0.9707 ROC-AUC) ve Kalp-Damar Riskinde %90.65 doğruluk (0.9856 ROC-AUC) başarı oranları elde edilmiştir. Modellerin ürettiği risk skorları ve etki eden temel parametreler SHAP (SHapley Additive exPlanations) yöntemiyle açıklanabilir hale getirilmiştir (Explainable AI - XAI). Elde edilen sayısal risk göstergeleri ve SHAP verileri, Gemini 2.5-Flash Büyük Dil Modeli (LLM) entegrasyonu ile tıbbi jargon içermeyen, hastaların rahatlıkla anlayabileceği klinik genel sağlık durum özetlerine ve risk düzeyine göre dallanan kişiselleştirilmiş yaşam tarzı tavsiyelerine dönüştürülmüştür. Yüksek riskli hastalar için klinik test komutları engellenerek evde öz bakım ve doktor randevu takibi vurgulanmıştır.

Sistem mimarisi; React.js (Vite) önyüz, Node.js/Express.js RESTful API, MongoDB veritabanı, Python FastAPI ML mikroservisi ve Socket.io gerçek zamanlı bildirim katmanından oluşan çok katmanlı mikroservis mimarisinde inşa edilmiştir. Sistem, doktor triyaj paneli ve hasta takip modülleriyle uçtan uca doğrulanmıştır.

Anahtar Kelimeler: Klinik Karar Destek Sistemi (CDSS), Makine Öğrenmesi, XGBoost, eGFR (CKD-EPI), Aterojenik Plazma İndeksi (AIP), SHAP, Gemini LLM, Kardiyovasküler-Böbrek-Metabolik (CKM) Sendromu.

ABSTRACT

In contemporary healthcare systems, early diagnosis of chronic diseases and personalized risk assessment play a vital role in enhancing patient quality of life and reducing healthcare expenditures. Diabetes mellitus, chronic kidney disease (CKD), and cardiovascular diseases (CVD) represent interconnected pathological processes recognized clinically under the Cardiovascular-Kidney-Metabolic (CKM) syndrome continuum. However, conventional clinical diagnostic tools typically focus on isolated single-disease targets, leading to fragmented and incomplete evaluations of overall patient health profiles.

In this study, an end-to-end artificial intelligence-powered web-based Clinical Decision Support System (CDSS) was developed to simultaneously predict multi-target risks for diabetes, renal impairment, and cardiovascular disease using routine biochemical blood panels and demographic observations from 5132 patients. Unlabeled renal and cardiovascular outcomes were synthesized using a clinical rule-based synthetic labeling framework grounded in international medical guidelines, specifically KDIGO (CKD-EPI 2021 eGFR equation) and AHA/ACC (Atherogenic Index of Plasma - AIP).

Machine learning classification pipelines incorporating XGBoost, Random Forest, and Logistic Regression algorithms were trained and cross-validated. The fully integrated XGBoost pipeline achieved classification accuracies of 83.15% (0.9114 ROC-AUC) for Diabetes, 87.44% (0.9707 ROC-AUC) for Kidney Risk, and 90.65% (0.9856 ROC-AUC) for Cardiovascular Risk. Model transparency was established via SHAP (SHapley Additive exPlanations) feature attribution analyses (Explainable AI - XAI). The quantitative risk probabilities and SHAP explanations were processed through a Gemini 2.5-Flash Large Language Model (LLM) pipeline, synthesizing empathetic, jargon-free Turkish health status summaries and risk-branched lifestyle recommendations. For high-risk patients, clinical test orders were suppressed in favor of self-care habits and doctor appointment compliance.

The system was engineered using a multi-tier microservices architecture comprising a React.js (Vite) frontend, Node.js/Express.js RESTful API with MongoDB, Python FastAPI ML service, and Socket.io real-time notifications. The CDSS was fully validated via doctor triage dashboards and patient management modules.

Keywords: Clinical Decision Support System (CDSS), Machine Learning, XGBoost, eGFR (CKD-EPI), Atherogenic Index of Plasma (AIP), SHAP, Gemini LLM, Cardiovascular-Kidney-Metabolic (CKM) Syndrome.

İÇİNDEKİLER

<i>ÖZET</i>	<i>ii</i>
<i>ABSTRACT</i>	<i>iii</i>
<i>İÇİNDEKİLER</i>	<i>iv</i>
<i>TABLOLAR DİZİNİ</i>	<i>v</i>
<i>ŞEKİLLER DİZİNİ</i>	<i>vi</i>
<i>SİMGELER VE KISALTMALAR DİZİNİ</i>	<i>vii</i>
<i>1. GİRİŞ</i>	<i>1</i>
<i>2. LİTERATÜR ARAŞTIRMASI VE KURAMSAL TEMELLER</i>	<i>2</i>
<i>3. VERİ SETİ, ÖN İŞLEME VE ŞARTLI SENTETİK ETİKETLEME</i>	<i>4</i>
<i>4. ÇOKLU-HEDEF MAKİNE ÖĞRENMESİ MODELLEMESİ, PERFORMANS VE AÇIKLANABİLİRLİK</i>	<i>7</i>
<i>5. SİSTEM MİMARİSİ, YAZILIM TASARIMI VE LLM ENTEGRASYONU</i>	<i>10</i>
<i>6. KLİNİK UYGULAMA VE ARAYÜZ TASARIMI</i>	<i>12</i>
<i>7. ETİK, VERİ GİZLİLİĞİ VE MEDİKAL GÜVENLİK</i>	<i>16</i>
<i>8. SONUÇ VE GELECEK ÇALIŞMALAR</i>	<i>16</i>
<i>KAYNAKÇA</i>	<i>17</i>
<i>EKLER</i>	<i>18</i>

TABLÖLAR DİZİNİ

<i>Tablo 1. Veri Seti Değişkenleri, Veri Tipleri ve Klinik İşlevleri</i>	<i>4</i>
<i>Tablo 2. KDIGO 2021 eGFR Evreleme ve Klinik Böbrek Riski Puanlama Algoritması</i>	<i>5</i>
<i>Tablo 3. AHA/ACC Aterojenik Plazma İndeksi (AIP) Kardiyovasküler Risk Puanlaması</i>	<i>6</i>
<i>Tablo 4. Diyabet, Böbrek ve Kalp Riski Modellerine Ait Karşılaştırmalı Performans Metrikleri</i>	<i>7</i>
<i>Tablo 5. Kan Testi Veri Giriş Alanları Bilimsel Referans Aralıkları ve Sınır Değerleri</i>	<i>13</i>

ŞEKİLLER DİZİNİ

<i>Şekil 1. Çoklu-Hedef Makine Öğrenmesi Modelleri Performans Karşılaştırma Grafiği</i>	<i>8</i>
<i>Şekil 2. Modellerin Karmaşıklık Matrisleri (Confusion Matrices)</i>	<i>9</i>
<i>Şekil 3. Çoklu-Hedef Modellerine Ait ROC Eğrileri ve AUC Değerleri</i>	<i>9</i>
<i>Şekil 4. Modeller İçin En Önemli 10 Biyokimyasal ve Demografik Öznitelik</i>	<i>10</i>
<i>Şekil 5. SHAP (Açıklanabilir AI) Global Öznitelik Etki Analizi</i>	<i>10</i>
<i>Şekil 6. Dağıtık Mikroservis Sistem Mimarisi ve Veri Akış Diyagramı</i>	<i>11</i>
<i>Şekil 7. Rol Tabanlı Kimlik Doğrulama ve Giriş Arabirimi</i>	<i>13</i>
<i>Şekil 8. Doktor Paneli Takipli Hasta Listesi ve Laboratuvar Veri Giriş Ekranı</i>	<i>14</i>
<i>Şekil 9. Klinik Triyaj ve Risk Önceliklendirme Kuyruğu (Doktor Görünümü)</i>	<i>14</i>
<i>Şekil 10. Açıklanabilir Yapay Zeka (XAI) ve SHAP Faktör Analiz Modalı</i>	<i>15</i>
<i>Şekil 11. Klinik Rapor Onaylama ve LLM Metni Düzenleme Modalı</i>	<i>15</i>
<i>Şekil 12. Hasta Paneli Geçmiş Analizler ve Onay Durumu Arşivi</i>	<i>16</i>
<i>Şekil 13. Hasta Paneli Doktor Onaylı Rapor ve Yaklaşan Randevu Görünümü</i>	<i>16</i>

SİMGELER VE KISALTMALAR DİZİNİ

- AIP: Aterojenik Plazma İndeksi (Atherogenic Index of Plasma)
- AUC: Eğri Altında Kalan Alan (Area Under Curve)
- BMI: Vücut Kitle İndeksi (Body Mass Index)
- BUN: Kan Üre Azotu (Blood Urea Nitrogen)
- CDSS: Klinik Karar Destek Sistemi (Clinical Decision Support System)
- CKD: Kronik Böbrek Hastalığı (Chronic Kidney Disease)
- CKD-EPI: Chronic Kidney Disease Epidemiology Collaboration
- CKM: Kardiyovasküler-Böbrek-Metabolik Sendromu
- CVD: Kardiyovasküler Hastalık (Cardiovascular Disease)
- EDA: Keşifsel Veri Analizi (Exploratory Data Analysis)
- eGFR: Tahmini Glomerüler Filtrasyon Hızı (estimated Glomerular Filtration Rate)
- FN: Yanlış Negatif (False Negative)
- FP: Yanlış Pozitif (False Positive)
- GDPR: Genel Veri Koruma Tüzüğü (General Data Protection Regulation)
- HbA1c: Glikozillenmiş Hemoglobin
- HDL: Yüksek Yoğunluklu Lipoprotein (High-Density Lipoprotein)
- KDIGO: Kidney Disease: Improving Global Outcomes
- KVKK: Kişisel Verilerin Korunması Kanunu
- LDL: Düşük Yoğunluklu Lipoprotein (Low-Density Lipoprotein)
- LLM: Büyük Dil Modeli (Large Language Model)
- ML: Makine Öğrenmesi (Machine Learning)
- OGTT: Oral Glikoz Tolerans Testi
- REST: Temsili Durum Transferi (Representational State Transfer)
- ROC: Alıcı İşletim Karakteristiği (Receiver Operating Characteristic)
- SHAP: SHapley Additive exPlanations
- TN: Doğru Negatif (True Negative)
- TP: Doğru Pozitif (True Positive)
- XAI: Açıklanabilir Yapay Zeka (Explainable Artificial Intelligence)
- XGBoost: eXtreme Gradient Boosting

1. GİRİŞ

1.1. Problemin Tanımı ve Motivasyon

Biyokimyasal kan testleri, modern tıpta hastaların sağlık durumunun değerlendirilmesinde, organ fonksiyonlarının incelenmesinde ve hastalıkların teşhisinde en yaygın kullanılan temel tanı araçlarıdır. Açlık kan şekeri, HbA1c, lipid profili (kolesterol, trigliserid, HDL, LDL), serum kreatinin ve kan üre azotu (BUN) gibi rutin laboratuvar parametreleri, insan metabolizmasının dinamik durumuna ilişkin zengin ve kritik bilgiler barındırmaktadır.

Ancak geleneksel sağlık hizmeti süreçlerinde bu laboratuvar verileri sıklıkla izole ve tek tek parametre bazlı değerlendirilmektedir. Hekimlerin yoğun poliklinik şartlarında yüzlerce hasta sonucunu aynı anda analiz ederken, parametreler arasındaki karmaşık ve lineer olmayan ilişkileri eş zamanlı olarak gözden kaçırması mümkündür. Ayrıca hastalar tahlil sonuçlarını aldıklarında, tıbbi terim karmaşası nedeniyle kendi sağlık durumlarını anlamakta güçlük çekmekte ve kaygı yaşamaktadırlar. Bu durum, sağlık sistemlerinde hem klinik tanı verimliliğinin düşmesine hem de önlenebilir kronik hastalıkların ilerlemesine yol açmaktadır.

1.2. Kardiyovasküler-Böbrek-Metabolik (CKM) Sendromunun Klinik Önemi

Son dönem tıp literatüründe (Amerikan Kalp Derneği - AHA 2023 kılavuzları), diyabet, kronik böbrek yetmezliği ve kardiyovasküler patolojilerin birbiriyle sıkı bir patofizyolojik bağ içinde olduğu tanımlanmış ve bu tablo Kardiyovasküler-Böbrek-Metabolik (CKM) Sendromu olarak adlandırılmıştır.

Metabolik bozukluklar (yüksek kan şekeri ve insülin direnci), damar yapısını bozarak kardiyovasküler sistemi olumsuz etkilerken, aynı zamanda böbrek kılcal damarlarında (glomerül) hasar oluşturarak süzme fonksiyonunu düşürmektedir. Diğer taraftan böbrek fonksiyonlarındaki bozulma, sodyum ve sıvı tutulumuna yol açarak hipertansiyonu tetiklemekte ve kalp üzerindeki yükü artırmaktadır. Dolayısıyla bu üç organ sisteminin risk değerlendirmesinin birbirinden bağımsız yapılması klinik açıdan eksik sonuçlar doğurmaktadır. Rutin bir biyokimya panelinden bu üç kronik riski eş zamanlı tahmin eden sistemlere duyulan ihtiyaç son derece yüksektir.

1.3. Çalışmanın Amacı ve Kapsamı

Bu projenin temel amacı; bireylere ait rutin biyokimyasal kan tahlili verilerini kullanarak Diyabet, Böbrek Yetmezliği Riski ve Kardiyovasküler Hastalık Riski olmak üzere 3 farklı kronik durumu eş zamanlı ve yüksek doğrulukla tahmin eden, Açıklanabilir Yapay Zeka (SHAP) ve Büyük Dil Modeli (Gemini LLM) entegrasyonuna sahip çok katmanlı bir Klinik Karar Destek Sistemi (CDSS) tasarlamak ve geliştirmektir.

Çalışma kapsamında:

1. Kaggle açık kaynak platformundaki 5132 hastaya ait biyokimya veri seti incelenmiş ve temizlenmiştir.
2. Veri setinde doğrudan etiketi bulunmayan Böbrek ve Kalp-Damar hastalık riskleri için uluslararası KDIGO (CKD-EPI 2021) ve AHA/ACC (AIP) klinik standartlarına dayalı şartlı sentetik etiketleme metodolojisi geliştirilmiştir.
3. XGBoost, Random Forest ve Lojistik Regresyon modelleri eğitilmiş, hiperparametre optimizasyonu ve çapraz doğrulama ile modellerin doğruluğu artırılmıştır.
4. SHAP algoritması ile modellerin kara kutu (black-box) yapısı kırılarak hekimler için açıklanabilirlik (XAI) sağlanmıştır.
5. Gemini 2.5-Flash LLM modeli ile sayısal riskler hastaların rahatlıkla anlayabileceği sade Türkçe klinik özetlere ve risk düzeyine göre dallanan (yüksek risklilerde test komutu vermeyen) yaşam tarzı tavsiyelerine dönüştürülmüştür.
6. React.js, Node.js/Express, MongoDB ve Python FastAPI teknolojileri ile klinik triyaj ve hasta takip süreçlerini içeren web tabanlı CDSS yazılımı kurulmuştur.

1.4. Projenin Özgün Değeri ve Katkıları

Bu çalışmanın literatüre ve bilişim uygulamalarına sağladığı temel özgün katkılar şunlardır:

- Çoklu-Hedefli Holistik Klinik Değerlendirme: Tek bir biyokimya verisinden CKM sendromunun 3 temel bileşenini aynı anda tahmin eden bütüncül yaklaşım.
- Klinik Kılavuz Tabanlı Şartlı Sentetik Etiketleme: Etiketsiz veriler üzerinde rastgele sınıflandırma yerine tıbbi denklemlere (CKD-EPI 2021 ve AIP) dayalı güvenilir sentetik etiket üretimi.
- Açıklanabilir AI (XAI) Entegrasyonu: Hekimlerin AI kararlarına güvenmesini sağlayan SHAP öznitelik katkı analizi.
- Risk-Dallanmalı Hekim LLM Motoru: Yüksek riskli hastaları gereksiz tetkik yönlendirmeleriyle yormayan, evde öz bakım ve doktor randevusuna odaklanan akıllı LLM prompt mimarisi.

1.5. Raporun Organizasyonu

Raporun devam eden bölümlerinde; Bölüm 2'de literatür araştırması ve teorik altyapı, Bölüm 3'te veri ön işleme ve sentetik etiketleme metodolojisi, Bölüm 4'te makine öğrenmesi modelleri, deneysel performans metrikleri ve SHAP açıklamaları, Bölüm 5'te dağıtık sistem mimarisi ve LLM entegrasyonu, Bölüm 6'da klinik web arayüz tasarımları, Bölüm 7'de etik ve veri güvenliği ilkeleri, Bölüm 8'de ise genel sonuç ve gelecek çalışmalar ele alınmaktadır.

2. LİTERATÜR ARAŞTIRMASI VE KURAMSAL TEMELLER

2.1. Sağlıkta Makine Öğrenmesi ve Klinik Karar Destek Sistemleri (CDSS)

Klinik Karar Destek Sistemleri (CDSS); tıbbi bilgileri ve hasta verilerini analiz ederek klinisyenlere tanı ve tedavi süreçlerinde kanıta dayalı öneriler sunan bilgisayar yazılımlarıdır. Geleneksel CDSS'ler kural tabanlı (if-then) uzman sistemlerden oluşurken, modern CDSS'ler karmaşık veri desenlerini öğrenebilen makine öğrenmesi ve derin öğrenme algoritmalarına dayanmaktadır.

2.2. Kardiyovasküler-Böbrek-Metabolik (CKM) Hastalıklarda Çoklu-Hedef Makine Öğrenmesi Literatürü

Sağlık bilişimi literatüründeki mevcut makine öğrenmesi çalışmaları incelendiğinde, araştırmaların ezici bir çoğunluğunun hastalıkları bağımsız ve isolated (tekil) hedefler olarak ele aldığı görülmektedir. Diyabet tahmini üzerine odaklanan ulusal ve uluslararası çalışmalarda (Kavakiotis ve ark., 2017; Ergün ve İlhan, 2021; Nahzat ve Yağanoğlu, 2021), glikoz, HbA1c ve lipid profili üzerinden yalnızca diyabet varlığı sınıflandırılmış; Random Forest, SVM ve XGBoost algoritmalarının %90-%98 bandında doğruluk yakaladığı gösterilmiştir.

Benzer şekilde, böbrek fonksiyonları (Gül ve Temurtaş, 2022) ve kardiyovasküler risk tahmini (Bozkurt ve Yıldırım, 2020; Weng ve ark., 2017) üzerine yürütülen çalışmalar da hastayı tek bir patoloji üzerinden değerlendiren münferit modeller sunmaktadır.

Ancak güncel tıp literatüründe (AHA/ACC ve KDIGO 2024 kılavuzları), Diyabet, Kronik Böbrek Hastalığı ve Kardiyovasküler Hastalıkların birbirinden bağımsız olmadığı, birbirini doğrudan tetikleyen Kardiyovasküler-Böbrek-Metabolik (CKM) Sendromu bünyesinde bütüncül bir risk zinciri oluşturduğu vurgulanmaktadır. Bu çalışmada sunulan yaklaşım, literatürdeki tekil hastalık tahmini sınırlamasını aşarak; tek bir rutin biyokimya verisinden CKM sendromunun her 3 risk boyutunu (Diyabet, KDIGO Renal Risk ve AHA/ACC Kardiyovasküler Risk) eş zamanlı ve çoklu-hedefli (multi-target) olarak değerlendiren özgün bir karar destek mimarisi sunmaktadır.

2.3. KDIGO Kılavuzu ve eGFR (CKD-EPI 2021) Formülasyonu

Böbrek fonksiyonlarının değerlendirilmesinde uluslararası en güncel referans KDIGO (Kidney Disease: Improving Global Outcomes 2024) kılavuzudur. Böbreğin süzme kapasitesini gösteren Tahmini Glomerüler Filtrasyon Hızı (eGFR), ırk değişkenini dışarıda bırakan ve tıbbi eşitlik ilkesini savunan CKD-EPI (2021) eşitliği ile hesaplanmaktadır:

$$eGFR = 142 \times \min(Scr / \kappa, 1)^{\alpha} \times \max(Scr / \kappa, 1)^{(-1.2)} \times 0.9938^{Yaş} \times Cinsiyet \text{ Katsayısı}$$

Burada:

- Scr: Serum kreatinin değeri (mg/dL)
- κ : Kadınlar için 0.7, Erkekler için 0.9
- α : Kadınlar için -0.241, Erkekler için -0.302
- Cinsiyet Katsayısı: Kadınlar için 1.012, Erkekler için 1.0.

eGFR değeri < 60 mL/min/1.73m² olması böbrek fonksiyonunda kronik kayba işaret etmekte, < 15 olması ise evre 5 (böbrek yetmezliği) olarak sınıflandırılmaktadır.

2.4. AHA/ACC Kılavuzu ve Aterojenik Plazma İndeksi (AIP) Formülasyonu

Kardiyovasküler risk değerlendirmesinde geleneksel lipid parametrelerinin yanı sıra, Dobiášová (2004) tarafından geliştirilen ve AHA/ACC kılavuzlarında desteklenen Aterojenik Plazma İndeksi (AIP) aterojenik lipoprotein partikül büyüklüğünü temsil eden güçlü bir göstergedir:

$$\text{AIP} = \log_{10} \left(\frac{\text{Trigliserid (mmol/L)}}{\text{HDL Kolesterol (mmol/L)}} \right)$$

- $AIP < 0.11$: Düşük Kardiyovasküler Risk
- $0.11 \leq AIP \leq 0.21$: Orta Kardiyovasküler Risk
- $AIP > 0.21$: Yüksek Kardiyovasküler Risk.

Bozkurt ve Yıldırım (2020), kardiyovasküler risk tahmininde lipid parametreleri ve kan basıncı ölçümlerinin makine öğrenmesi modellerine entegrasyonunun klinik risk önceliklendirme başarısını %15 oranında artırdığını doğrulamıştır.

2.5. Açıklanabilir Yapay Zeka (XAI) ve SHAP Yöntemi

Sağlık alanında yapay zeka modellerinin klinik kabul görmesinin önündeki en büyük engel "kara kutu" (black-box) doğalarıdır. SHAP (SHapley Additive exPlanations), kooperatif oyun teorisindeki Shapley değerlerine dayanan, her bir özneliliğin (örneğin HbA1c veya Kreatinin) tahmin edilen risk skoruna katkısını (+ veya - yönlü) matematiksel olarak hesaplayan lider XAI yöntemidir.

2.6. Büyük Dil Modellerinin (LLM) Tıbbi İletişimdeki Rolü

Son dönemde gelişen Büyük Dil Modelleri (Gemini, Med-PaLM, GPT-4), karmaşık medikal verileri ve sayısal yapay zeka çıktılarını doğal dilde özetleme yeteneğine sahiptir. Singhal ve ark. (2023) tarafından Nature dergisinde yayımlanan çalışmada, tıbbi bilgi ile eğitilmiş büyük dil modellerinin klinik soru yanıtlama ve hasta bilgilendirme süreçlerinde uzman hekim düzeyine yakın başarımlar sergilediği gösterilmiştir. LLM'lerin klinik karar destek kullanımı; hekimlerin bürokratik raporlama yükünü hafifletmekte, hastaya kişiselleştirilmiş şefkatli öneriler sunmakta ve sağlık okuryazarlığını artırmaktadır.

3. VERİ SETİ, ÖN İŞLEME VE ŞARTLI SENTETİK ETİKETLEME

3.1. Veri Seti Yapısı, Keşifsel Analiz (EDA) ve Özellik Mühendisliği

Araştırmada kullanılan temel materyal, Kaggle açık kaynak platformundan elde edilen ve 5132 hastaya ait rutin biyokimyasal kan paneli ile demografik ölçümleri içeren geniş ölçekli klinik veri setidir. Veri seti; hastaların yaş ve cinsiyet bilgilerinden glisemik değerlere, lipid profilinden renal fonksiyon parametrelerine kadar toplam 12 temel klinik değişkenden ve 1 tanı etiketinden oluşmaktadır.

Tablo 1. Veri Seti Değişkenleri, Veri Tipleri ve Klinik İşlevleri

Öznitelik Grubu	Değişken Adı	Açıklama / Klinik İşlev	Veri Tipi	Referans Aralığı
Demografik	Age	Hastanın Yaşı	Sayısal (Tamsayı)	1 - 120 Yaş
Demografik	Gender	Cinsiyet (1: Erkek, 0: Kadın)	Kategorik / İkili	0 veya 1
Fiziksel	BMI	Vücut Kitle İndeksi (kg/m ²)	Sayısal (Sürekli)	10.0 - 70.0
Hemodinamik	SBP / DBP	Sistolik / Diyastolik Kan Basıncı (mmHg)	Sayısal (Sürekli)	70-250 / 40-150
Glisemik	Glucose	Açlık Kan Şekeri (mg/dL)	Sayısal (Sürekli)	40 - 500 mg/dL
Glisemik	HbA1c	Glikozillenmiş Hemoglobin (%)	Sayısal (Sürekli)	%3.0 - 18.0
Lipid Paneli	Cholesterol	Toplam Kolesterol (mg/dL)	Sayısal (Sürekli)	80 - 500 mg/dL
Lipid Paneli	HDL / LDL	İyi / Kötü Kolesterol (mg/dL)	Sayısal (Sürekli)	10-150 / 20-400
Lipid Paneli	Triglycerides	Trigliserid Yağ Düzeyi (mg/dL)	Sayısal (Sürekli)	30 - 1000 mg/dL
Renal Panel	Creatinine	Serum Kreatinin (mg/dL)	Sayısal (Sürekli)	0.2 - 15.0 mg/dL
Renal Panel	BUN	Kan Üre Azotu (mg/dL)	Sayısal (Sürekli)	2.0 - 100.0 mg/dL
Hedef Etiket	Diagnosis	Diyabet Tanı Etiket (0/1)	İkili (Binary)	0 (Sağlıklı), 1 (Hasta)

Veri temizleme adımlarında; 5132 gözlem detaylı bir eksik değer (missing value) ve uç değer (outlier) denetiminden geçirilmiştir. Veri setinde hiçbir eksik gözlem bulunmadığı saptanmıştır. Popülasyonun yaş ortalaması 48.2 ± 14.3 yıl, BMI ortalaması ise 25.4 ± 4.8 kg/m² olarak ölçülmüştür. Ham diyabet etiketinde %62 (3182 hasta) sağlıklı, %38 (1950 hasta) diyabetik hasta oranı ile dengeli ve sınıflandırmaya elverişli bir dağılım gözlemlenmiştir.

Öznitelik mühendisliği (Feature Engineering) aşamasında, ham kan parametreleri arasındaki biyokimyasal etkileşimleri modele aktarmak üzere klinik literatüre dayalı 3 yeni öznitelik hesaplanmıştır:

- Ortalama Arter Basıncı (MAP): $MAP = DBP + 1/3 * (SBP - DBP)$ formülü ile türetilerek organların maruz kaldığı gerçek perfüzyon basıncı modellenmiştir.
- Trigliserid / HDL Oranı: İnsülin direnci ve metabolik sendrom varlığının en hassas plazma göstergesi olarak sisteme eklenmiştir.
- Non-HDL Kolesterol: $Toplam\ Kolesterol - HDL$ formülü ile hesaplanarak koroner arter hastalığı riskini belirleyen atherojenik apoB lipoprotein yükü temsil edilmiştir.

Veri seti, model eğitiminde sızıntıyı (data leakage) engellemek amacıyla %80 Eğitim (4105 hasta) ve %20 Bağımsız Test (1027 hasta) olarak stratified (tabakalı) biçimde ayrılmış, tüm sayısal öznitelikler eğitim verisinin ortalama ve standart sapması ile **StandardScaler** standardizasyonuna tabi tutulmuştur.

3.2. KDIGO ve AHA/ACC Standartlarında Klinik Şartlı Sentetik Etiketleme Metodolojisi

Veri setinde doğrudan diyabet etiketi klinik tanı olarak bulunurken, böbrek fonksiyon bozukluğu ve kardiyovasküler hastalık risk etiketleri mevcut değildi. Bu eksikliği gidermek amacıyla rastgele etiket ataması yerine uluslararası tıp kılavuzlarının (KDIGO 2021 ve AHA/ACC) önerdiği klinik şartlı kurallara dayalı etiketleme yapılmıştır.

Metodolojik Kısıtlılık ve Vekil Model (Surrogate Model) Çerçevesi:

Böbrek ve Kalp risk etiketleri doğrudan bağımsız hasta teşhislerinden değil, tıp kılavuzlarındaki formül ve eşik değerlerinden sentetik olarak üretilmiştir. Bu nedenle eğitilen XGBoost modelleri, bu iki hedef değişkende bağımsız hastalık teşhisi yapmaktan ziyade, karmaşık ve çok parametrelili klinik karar kurallarını milisaniyeler düzeyinde tahmin eden kural tabanlı bir klinik vekil model (surrogate model) işlevi görmektedir.

Jüri İçin Metodolojik Gerekçe: Neden Kural Tabanlı İndeksler ML (XGBoost) ile Modellenmiştir?

"Formülle tanımlı bir klinik kuralı doğrudan hesaplamak yerine neden makine öğrenmesi ile tahmin ettiriyorsunuz?" sorusunun metodolojik gerekçesi üç temel nedene dayanmaktadır:

1. İnferans Hızı ve Kural Motoru İkamesi (Rule Acceleration): Parçalı üslü eGFR denklemleri (KDIGO 2021) ve logaritmik AIP indeksleri (AHA/ACC), yoğun klinik otomasyon sistemlerinde sürekli hesaplama yükü yaratır. XGBoost, bu karmaşık tıp kurallarını $\mathcal{O}(1)$ süresinde çalışan mikroservis seviyesine indirgeyerek performans optimizasyonu sağlar.

2. Ortak Olasılıksal Risk Ölçekleme (%0 - %100): Kılavuz kuralları kesikli (discrete) puanlar üretirken, XGBoost modelleri sürekli risk olasılığı üreterek hassas triyaj imkanı sunar.

3. Bütüncül Açıklanabilirlik (SHAP XAI Framework): Doğrudan tanı olan Diyabet ile vekil model olan Böbrek ve Kalp risklerini tek bir ortak SHAP açıklanabilirlik katmanında birleştirmeyi mümkün kılar.

Böbrek riski etiketlemesinde KDIGO 2021 (CKD-EPI) standartları uygulanmıştır. Her hasta için önce yaş, cinsiyet ve kreatinin değerlerinden eGFR hesaplanmış, ardından klinik risk puanı oluşturulmuştur.

Tablo 2. KDIGO 2021 eGFR Evreleme ve Klinik Böbrek Riski Puanlama Algoritması

Öznitelik / Kategori	Klinik Gösterge / Evre	Atanan Klinik Risk Puanı
eGFR (CKD-EPI 2021)	eGFR < 15 mL/min/1.73m ² (Evre G5 - Böbrek Yetmezliği)	+5 Puan
eGFR (CKD-EPI 2021)	15 ≤ eGFR < 30 mL/min/1.73m ² (Evre G4 - Ağır Hasar)	+4 Puan
eGFR (CKD-EPI 2021)	30 ≤ eGFR < 45 mL/min/1.73m ² (Evre G3b - Orta-Ağır Hasar)	+3 Puan
eGFR (CKD-EPI 2021)	45 ≤ eGFR < 60 mL/min/1.73m ² (Evre G3a - Hafif-Orta Hasar)	+2 Puan
eGFR (CKD-EPI 2021)	60 ≤ eGFR < 90 mL/min/1.73m ² (Evre G2 - Hafif Kayıp)	+1 Puan
eGFR (CKD-EPI 2021)	eGFR ≥ 90 mL/min/1.73m ² (Evre G1 - Normal)	0 Puan
Serum Kreatinin	Serum Kreatinin ≥ 1.3 mg/dL	+2 Puan
Kan Üre Azotu (BUN)	BUN ≥ 24 mg/dL	+2 Puan
Klinik Komorbidite	Diyabet Tanısı Varlığı (Diagnosis = 1)	+1 Puan
Demografik Faktör	İleri Yaş (Yaş ≥ 60)	+1 Puan

Toplam Puan Sınıflandırması:

- 0 - 1 Puan: Düşük Risk (Evre 0)
- 2 - 4 Puan: Orta Risk (Evre 1)
- 5 ve Üzeri Puan: Yüksek Risk (Evre 2)

Kardiyovasküler risk etiketlemesinde ise AHA/ACC kılavuzlarında tanımlanan Aterojenik Plazma İndeksi (AIP), kan basıncı evreleri ve lipid eşikleri birleştirilmiştir.

Tablo 3. AHA/ACC Aterojenik Plazma İndeksi (AIP) Kardiyovasküler Risk Puanlaması

Öznitelik / Kategori	Klinik Gösterge / Koşul	Atanan Klinik Risk Puanı
AIP İndeksi	$AIP \geq 0.21$ (Yüksek Risk)	+2 Puan
AIP İndeksi	$0.11 \leq AIP < 0.21$ (Orta Risk)	+1 Puan
Kan Basıncı	Sistolik BP ≥ 140 mmHg veya Diyastolik BP ≥ 90 mmHg	+2 Puan
Kan Basıncı	$130 \leq$ Systolik BP < 140 mmHg veya $80 \leq$ Diyastolik BP < 90 mmHg	+1 Puan
Lipid Profili	Toplam Kolesterol ≥ 240 mg/dL veya LDL ≥ 160 mg/dL	+2 Puan
Komorbidite	Diyabet Varlığı (Diagnosis = 1)	+2 Puan
Demografi & Obezite	Yaş ≥ 50 veya Vücut Kitle İndeksi (BMI) ≥ 30 kg/m ²	+1 Puan

Toplam Puan Sınıflandırması:

- 0 - 2 Puan: Düşük Risk (Evre 0)
- 3 - 5 Puan: Orta Risk (Evre 1)
- 6 ve Üzeri Puan: Yüksek Risk (Evre 2)

4. ÇOKLU-HEDEF MAKİNE ÖĞRENMESİ MODELLEMESİ, PERFORMANS VE AÇIKLANABİLİRLİK

4.1. Çoklu-Hedef Sınıflandırma Algoritmaları ve Eğitim Pipeline'ı

Sistem mimarisinde tek bir ortak yapay sinir ağı (Multi-Task Learning) yerine, tek bir biyokimya girdisi üzerinden 3 farklı CKM riskini eş zamanlı ve bağımsız olarak değerlendiren 3 paralel XGBoost sınıflandırıcısı konumlandırılmıştır.

Klinik İkileştirme (Binarization Threshold) Mantığı:

KDIGO ve AHA/ACC risk puanları 3 sınıflı (Evre 0: Düşük, Evre 1: Orta, Evre 2: Yüksek) kategorik yapıda üretilmiştir. Ancak klinik triyaj mimarisinde acil müdahale ve hekim incelemesi gerektiren vakaları önceliklendirmek amacıyla risk etiketleri ikili (binary) sınıfa indiren klinik eşikleme uygulanmıştır:

- Negatif Sınıf (0 - Sağlıklı / Normal): Evre 0 (Düşük Risk)
- Pozitif Sınıf (1 - Klinik Eylem Gerektiren Risk): Evre 1 (Orta Risk) ve Evre 2 (Yüksek Risk).

Bu binarizasyon sayesinde klinik ortamda herhangi bir düzeyde risk taşıyan hastaların triyaj kuyruğuna düşmesi garanti altına alınmıştır.

Çalışmada tabüler biyokimya verilerinde üstün başarımlar sergileyen 3 farklı makine öğrenmesi algoritması kıyaslamalı olarak eğitilmiştir:

1. XGBoost (eXtreme Gradient Boosting): Gradyan artırma yaklaşımına dayanan, ağaç derinliğini ve yaprak ağırlıklarını düzenliştiren (L1/L2 regularization) gelişmiş bir karar ağacı topluluğudur. Biyokimyasal parametreler arasındaki doğrusal olmayan karmaşık ilişkileri ve etkileşimleri yakalamakta en yüksek başarıyı sağlamıştır.

2. Random Forest: Rastgele öznelik ve örneklem alt kümeleriyle oluşturulan çoklu karar ağaçlarının oylamasına dayanan kolektif (ensemble) sınıflandırıcıdır. Aşırı öğrenmeye karşı direnci ve kararlılığı ile bilinmektedir.

3. Lojistik Regresyon: Geleneksel biyoistatistikte klinik risk analizlerinin temel referans noktası (baseline) kabul edilen doğrusal olasılıksal modeldir.

Model optimizasyon sürecinde, 4105 hastadan oluşan eğitim kümesi üzerinde 5-Katlı Çapraz Doğrulama (5-Fold Cross-Validation) ve **GridSearchCV** ile hiperparametre taraması yapılmıştır. XGBoost modeli için optimum parametreler: **n_estimators=200**, **max_depth=5**, **learning_rate=0.05**, **subsample=0.8** ve **colsample_bytree=0.8** olarak belirlenmiştir.


4.2. Karşılaştırmalı Performans Analizi, Karmaşıklık Matrisleri ve ROC-AUC Değerlendirmesi

Eğitilen modeller, daha önce hiç görülmemiş 1027 hastalık bağımsız test seti üzerinde 5 farklı akademik performans metriği ile değerlendirilmiştir.

Tablo 4. Diyabet, Böbrek ve Kalp Riski Sınıflandırma Modellerine Ait Karşılaştırmalı Performans Metrikleri

Hedef Risk / Hastalık	Model Algoritması	Accuracy (Doğruluk)	Pozitif Precision	Pozitif Recall	F1-Score	ROC-AUC
Diyabet Tahmini	XGBoost Classifier (En İyi)	%83.15	0.7547	0.7164	0.7350	0.9114
Diyabet Tahmini	Random Forest Classifier	%81.40	0.7380	0.6980	0.7174	0.8950
Diyabet Tahmini	Lojistik Regresyon	%77.20	0.6920	0.6510	0.6709	0.8420
Böbrek Riski (KDIGO)	XGBoost Classifier (En İyi)	%87.44	0.8464	0.7470	0.7936	0.9707
Böbrek Riski (KDIGO)	Random Forest Classifier	%85.80	0.8250	0.7290	0.7740	0.9540
Böbrek Riski (KDIGO)	Lojistik Regresyon	%80.10	0.7680	0.6710	0.7162	0.8870
Kalp Riski (AHA/ACC)	XGBoost Classifier (En İyi)	%90.65	0.8533	0.7921	0.8216	0.9856
Kalp Riski (AHA/ACC)	Random Forest Classifier	%88.90	0.8310	0.7670	0.7977	0.9710
Kalp Riski (AHA/ACC)	Lojistik Regresyon	%82.50	0.7650	0.6980	0.7300	0.9030

Şekil 1. Çoklu-Hedef Makine Öğrenmesi Modelleri Performans Karşılaştırması




Şekil 1. Çoklu-Hedef Makine Öğrenmesi Modelleri Performans Karşılaştırma Grafiği

Tüm testlerde XGBoost algoritması, her üç hedef değişkende de en yüksek başarımları elde etmiştir. Diyabet tahmininde %83.15 doğruluk (0.9114 ROC-AUC), Böbrek Riskinde %87.44 doğruluk (0.9707 ROC-AUC) ve Kalp-Damar Riskinde %90.65 doğruluk (0.9856 ROC-AUC) değerlerine ulaşılmıştır.

Klinik karar destek sistemlerinde Yanlış Negatif (FN) oranının düşük olması, yüksek riskli hastaların gözden kaçırılmaması açısından en kritik şarttır. 1027 kişilik bağımsız test kümesi ($N_{test} = 1027$) üzerindeki karmaşıklık matrisleri (Confusion Matrices) incelendiğinde matematiksel olarak şu metrikler hesaplanmıştır:


- Diyabet Modeli ($N = 1027$): $TN = 614$, $FP = 78$, $FN = 95$, $TP = 240$. (Doğruluk: $854/1027 = \%83.15$, Pozitif Sınıf Duyarlılığı [$TP/(TP+FN)$]: $240/335 = 0.7164$, Ağırlıklı Ortalama Duyarlılık: 0.8315).
- Böbrek Riski Modeli ($N = 1027$): $TN = 650$, $FP = 45$, $FN = 84$, $TP = 248$. (Doğruluk: $898/1027 = \%87.44$, Pozitif Sınıf Duyarlılığı [$TP/(TP+FN)$]: $248/332 = 0.7470$, Ağırlıklı Ortalama Duyarlılık: 0.8744).
- Kalp-Damar Riski Modeli ($N = 1027$): $TN = 710$, $FP = 38$, $FN = 58$, $TP = 221$. (Doğruluk: $931/1027 = \%90.65$, Pozitif Sınıf Duyarlılığı [$TP/(TP+FN)$]: $221/279 = 0.7921$, Ağırlıklı Ortalama Duyarlılık: 0.9065).

Böbrek ve Kalp-Damar risklerindeki yüksek ROC-AUC skorları (%97-%98), modellerin kılavuz tabanlı klinik risk indeksini (KDIGO & AHA/ACC) çok yüksek bir sadakatle taklit eden birer vekil model (surrogate model) olarak başarıyla çalıştığını doğrulamaktadır.



Şekil 2. Modellerin Karmaşıklık Matrisleri (a: Diyabet, b: Böbrek Riski, c: Kalp-Damar Riski)

Farklı karar eşiklerinde model performansını sergileyen ROC (Receiver Operating Characteristic) eğrilerinin altında kalan alan (AUC) skorları 0.91 ile 0.98 arasında ölçülmüştür. Bu durum modellerin rastgele tahminin çok ötesinde mükemmel bir ayırıştırma gücüne ulaştığını kanıtlamaktadır.




Şekil 3. Çoklu-Hedef Modellerine Ait ROC Eğrileri ve AUC Değerleri

4.3. SHAP Tabanlı Açıklanabilir Yapay Zeka (XAI) ve Öznitelik Katkı Analizleri

Yapay zeka sistemlerinin hekimler tarafından klinik ortamda benimsenebilmesi için verilen risk kararlarının bilimsel gerekçelerinin şeffaf biçimde sunulması şarttır. Bu amaçla modeller **shap.TreeExplainer** algoritması ile entegre edilerek Açıklanabilir Yapay Zeka (XAI) katmanı inşa edilmiştir.


SHAP analizi, kooperatif oyun teorisine dayanarak her biyokimyasal parametrenin modelin pozitif risk olasılığı tahminine yaptığı marjinal istatistiksel katkısı (Shapley değeri) hesaplamaktadır. SHAP sonuçları nedensellik (causality) ima etmeyip, özniteliklerin model içi karar verme sürecindeki istatistiksel önemini göstermektedir.

Şekil 4. Modeller İçin En Önemli 10 Biyokimyasal ve Demografik Özn



Şekil 4. Modeller İçin En Önemli 10 Biyokimyasal ve Demografik Öznitelik

Şekil 5. SHAP (Açıklanabilir AI) Global Öznitelik Etki Analizi



Şekil 5. SHAP (Açıklanabilir AI) Global Öznitelik Etki Analizi


SHAP global öznitelik önem analizlerinde şu kritik klinik bulgular elde edilmiştir:

- Diyabet Modeli: En yüksek ağırlıklı parametre HbA1c (glikozillenmiş hemoglobin) ve Açlık Kan Şekeri'dir. Yüksek HbA1c değerlerinin risk skorunu doğrudan pozitif yönde etkilediği doğrulanmıştır.
- Böbrek Riski Modeli: En belirleyici öznitelikler Serum Kreatinin, eGFR ve BUN olmuştur. Kreatinin seviyesindeki artış ve eGFR'deki düşüş böbrek yetmezliği risk skorunu hızla yükseltmektedir.
- Kalp-Damar Riski Modeli: En yüksek katkı Sistolik Kan Basıncı, Aterojenik Plazma İndeksi (AIP) ve Non-HDL Kolesterol tarafından sağlanmıştır. Bu sonuçlar tıbbi AHA/ACC literatürü ile tam uyum göstermektedir.

5. SİSTEM MİMARİSİ, YAZILIM TASARIMI VE LLM ENTEGRASYONU

5.1. Çok Katmanlı Mikroservis Mimarisi (Distributed Architecture)

Geliştirilen Klinik Karar Destek Sistemi (CDSS); modülerlik, ölçeklenebilirlik ve yüksek performans ilkeleri doğrultusunda ayrıştırılmış çok katmanlı mikroservis mimarisinde tasarlanmıştır.



Şekil 6. Dağıtık Mikroservis Sistem Mimarisi ve Veri Akış Diyagramı

5.2. Sunucu Katmanı (Node.js/Express.js, MongoDB & JWT)

Sunucu katmanı, RESTful uç noktalar üzerinden iş mantığını yönetmektedir. Güvenlik için **jsonwebtoken** (JWT) kullanılmış, parola güvenliği **bcryptjs** ile sağlanmıştır. Veri tabanı olarak MongoDB tercih edilmiş; **User**, **PatientProfile**, **LabTest**, **Analysis** ve **Appointment** koleksiyonları oluşturulmuştur.

5.3. Yapay Zeka Servisi (Python FastAPI)

Python 3.10 ve FastAPI altyapısıyla geliştirilen ML mikroservisi (**main.py**), saniyede yüzlerce tahmin talebini işleyebilecek asenkron mimariye sahiptir. Servis, biyokimya verilerini aldığı anda XGBoost ve SHAP motorlarını çalıştırarak elde ettiği tahmin olasılıklarını ve öznitelik katkılarını JSON formatında Node.js sunucusuna iletmektedir.

5.4. Gemini 2.5-Flash LLM Entegrasyonu ve Prompt Mühendisliği

Sayısal risk olasılıklarının hastalar tarafından anlaşılabilmesi problemi çözmek amacıyla Google Gemini 2.5-Flash Büyük Dil Modeli sisteme entegre edilmiştir. Gemini API'sine gönderilen sistem talimatı (**SYSTEM_INSTRUCTION**), yapay zekaya uzman bir klinik karar destek asistanı rolü yüklemektedir.

5.5. Risk Düzeyine Göre Dinamik Tavsiye ve Dallanma Mantığı

LLM entegrasyonunda uygulanan en kritik kural Risk Düzeyine Göre Dinamik Dallanma Mantığı'dır:

- Kural Tabanlı Deterministik Güvenlik Katmanı (LLM Guardrails): Gemini LLM çıktıları istemciye sunulmadan önce regex ve şablon doğrulayıcılardan geçer. Halüsinasyon riskini önlemek adına doğrudan tıbbi teşhis ve reçete yazımı engellenmiştir.
- Sıvı Kısıtlaması ve Tıbbi Güvenlik Uyarısı: İleri evre böbrek ve kalp yetmezliği olan vakalarda kontrolsüz sıvı tüketimi (örneğin "2-2.5 L su tüketin" tavsiyesi) hipervolemi ve pulmoner ödem riski yaratabilir. Bu sebeple sistem, yüksek risk grubundaki tüm LLM önerilerini doktor onayına (**pending_approval**) tabi tutmakta ve hekim denetimi olmadan hastaya sunmamaktadır.
- Düşük / Orta Riskli Hastalar: Koruyucu sağlık tavsiyeleri, Akdeniz tipi beslenme, tempolu yürüyüş ve yıllık rutin kontroller önerilir.

5.6. Gerçek Zamanlı İletişim (Socket.io) ve PDF Raporlama Motoru


Doktor randevu oluşturduğunda veya rapor onayladığında Socket.io kanalı üzerinden hastanın ekranına anlık bildirim düşmektedir. Ayrıca onaylanan klinik raporlar **pdfkit** motoru ile resmi medikal PDF belgesi formatında indirilmektedir.

6. KLİNİK UYGULAMA VE ARAYÜZ TASARIMI

Geliştirilen Çoklu-Hedef Makine Öğrenmesi ve LLM Destekli Klinik Karar Destek Sistemi (CDSS); klinik iş akışına tam entegre, kullanıcı dostu ve modern bir web arayüzüne sahiptir. Bu bölümde, sistemin uçtan uca çalışmasını gösteren klinik ekran görüntüleri sırasıyla ele alınmıştır.

6.1. Güvenli Kimlik Doğrulama ve Rol Tabanlı Erişim (RBAC)

Sisteme erişim, medikal veri gizliliği standartlarına uygun olarak Rol Tabanlı Erişim Kontrolü (RBAC) ile korunmaktadır. Giriş ekranında Hasta Girişi ve Doktor Girişi olmak üzere iki ayrı sekme sunulmaktadır. Kullanıcı rolüne uygun olmayan sekmeden giriş yapmaya çalışıldığında istemci tarafında anlık doğrulama mekanizması çalışmakta ve yetkisiz erişim engellenmektedir.



Şekil 7. Rol Tabanlı Kimlik Doğrulama ve Giriş Arabirimi (LoginPage / Auth)


6.2. Doktor Paneli: Takipli Hasta Listesi ve Laboratuvar Veri Girişi

Hekim sisteme giriş yaptığında, kendisine bağlı takipli hastaların listesini, son tahlil tarihlerini ve hasta demografik bilgilerini görüntüleyebilmektedir. "Yeni Kan Testi Ekle" butonuyla tetiklenen modal ekranında, biyokimyasal kan parametreleri sisteme girilmektedir. Hatalı veri girişlerini engellemek amacıyla her veri alanına bilimsel referans aralıklarını gösteren dinamik aralıklar ve klavye geçerlilik kuralları entegre edilmiştir.

Tablo 5. Kan Testi Veri Giriş Alanları Bilimsel Referans Aralıkları ve Sınır Değerleri

Biyokimyasal Parametre	Ölçüm Birimi	Minimum Değer	Maksimum Değer	Normal Referans Aralığı
Açlık Kan Şekeri (Glucose)	mg/dL	40.0	500.0	70.0 - 99.0 mg/dL
HbA1c	%	3.0	18.0	%4.0 - %5.6
Sistolik Kan Basıncı (SBP)	mmHg	70.0	250.0	90.0 - 120.0 mmHg
Diastolik Kan Basıncı (DBP)	mmHg	40.0	150.0	60.0 - 80.0 mmHg
Serum Kreatinin	mg/dL	0.2	15.0	0.6 - 1.2 mg/dL
Kan Üre Azotu (BUN)	mg/dL	2.0	100.0	7.0 - 20.0 mg/dL
Toplam Kolesterol	mg/dL	80.0	500.0	120.0 - 200.0 mg/dL
HDL Kolesterol	mg/dL	10.0	150.0	40.0 - 60.0 mg/dL
LDL Kolesterol	mg/dL	20.0	400.0	50.0 - 130.0 mg/dL
Trigliserid	mg/dL	30.0	1000.0	50.0 - 150.0 mg/dL


Yukarıdaki referans değerleri doğrultusunda girilen laboratuvar ölçümleri, sistemin istemci tarafında anlık validasyondan geçirilerek sonucu katmanına iletilmektedir. Şekil 8'de, hekimin takipli hastalarını listelediği doktor ana paneli ve tahlil veri giriş modalı gösterilmektedir.



Şekil 8. Doktor Paneli Takipli Hasta Listesi ve Laboratuvar Veri Giriş Ekranı

6.3. Klinik Triyaj ve Risk Önceliklendirme Kuyruğu (Doktor Görünümü)


Laboratuvar tahlili girildiğinde arka planda çalışan XGBoost makine öğrenmesi hattı Diyabet, Böbrek (KDIGO) ve Kalp (AHA/ACC) risklerini hesaplar. Yüksek risk grubuna giren hastalar, doktor ana panelindeki kırmızılı İnceleme ve Onay Bekleyen Risk Analizleri (Klinik Triyaj Kuyruğu) kartında üst sırada yerleştirilir. Bu durum, acil müdahale gereken vakaların poliklinik yoğunluğunda gözden kaçmasını önlemektedir.



Şekil 9. Klinik Triyaj ve Risk Önceliklendirme Kuyruğu (Doktor Görünümü)

6.4. Açıklanabilir Yapay Zeka (XAI) ve SHAP Faktör Analiz Modalı


Hekim triyaj kuyruğundaki hastanın risk detayına tıkladığında "Yapay Zeka Risk Değerlendirmesi & SHAP Açıklanabilir Detayı" modalı açılır. Burada yapay zeka modelinin çıkardığı risk yüzdesi (örneğin Böbrek Fonksiyon Bozukluğu Riski %88.5) ve bu riske en çok katkı sağlayan ilk 3 biyokimyasal parametrenin (örneğin Kreatinin, BUN ve Kan Şekeri) SHAP etki değerleri grafiksel olarak sunulur.



Şekil 10. Açıklanabilir Yapay Zeka (XAI) ve SHAP Faktör Analiz Modalı

6.5. Klinik Rapor Onaylama ve LLM Metni Düzenleme Modalı


Yapay zeka analizinin hemen ardından Gemini 2.5-Flash LLM motoru, hasta için anlaşılır bir klinik özet metni ve risk düzeyine göre dallanan yaşam tarzı tavsiyeleri üretir. Hekim bu modal ekranında LLM tarafından oluşturulan metni klinik süzgecinden geçirir, gerekli görürse metin alanında düzenleme yapar, randevu tarihini seçerek raporu onaylar. Rapor onaylandığında hasta triyaj kuyruğundan düşer ve hastanın ekranına gerçek zamanlı (Socket.io) bildirim gönderilir.



Şekil 11. Klinik Rapor Onaylama ve LLM Metni Düzenleme Modalı

6.6. Hasta Paneli: Geçmiş Analizler ve Onay Durumu Arşivi


Hasta kendi hesabıyla giriş yaptığıında "Geçmiş Analizlerim" sayfasından daha önce yapılmış tüm kan tahlillerinin hekim onay durumunu ("Onaylandı" / "Beklemede") takip edebilir. Henüz hekim tarafından incelenmeyen tahliller hasta ekranında uyarı mesajı ile belirtilir.



Şekil 12. Hasta Paneli Geçmiş Analizler ve Onay Durumu Arşivi

6.7. Hasta Paneli: Doktor Onaylı Rapor ve Yaklaşan Randevu Görünümü

Hekim tarafından onaylanmış güncel sağlık raporu, hastanın ana panelinde gösterilir. Rapor içeriğinde karmaşık medikal terimler yerine hastanın anlayabileceği "Klinik Genel Sağlık Durumunuz" özeti, beslenme ve yaşam tarzı tavsiyeleri, doktor randevu saati ve "PDF Raporu İndir" seçeneği yer almaktadır. Yüksek riskli hastalar için klinik test yönlendirmeleri gizlenerek evde öz bakım ve doktor randevusuna sadakat vurgulanmaktadır.



Şekil 13. Hasta Paneli Doktor Onaylı Rapor ve Yaklaşan Randevu Görünümü

7. ETİK, VERİ GİZLİLİĞİ VE MEDİKAL GÜVENLİK

7.1. KVKK ve GDPR Uyumlu Veri Yönetimi

Hasta verilerinin gizliliği kapsamında; isim ve T.C. kimlik numaraları veritabanında şifrelenmiş, ML servisine gönderilen veriler anonimleştirilerek (**patient_id: P-DEMO**) KVKK ve GDPR veri minimizasyonu, rol tabanlı erişim kontrolü (RBAC) ve anonimleştirme ilkelerine uygun mimari tasarlanmıştır.

7.2. Yasal Sorumluluk Reddi (Medical Disclaimer) Çerçevesi

Sistem bir yapay zeka karar destek aracıdır ve kesinlikle bir hekimin yerine geçmez. Tüm analiz çıktı ekranlarında ve indirilen PDF raporlarında "Bu değerlendirme bilgilendirme amaçlıdır. Kesin teşhis ve tedavi için doktorunuza danışınız." yasal sorumluluk reddi metni yer almaktadır.

8. SONUÇ VE GELECEK ÇALIŞMALAR

8.1. Çalışmanın Sonuçları ve Elde Edilen Çıktılar

Bu çalışmada, rutin kan testlerinden diyabet, böbrek fonksiyon bozukluğu riski ve kardiyovasküler riskleri eş zamanlı ve yüksek başarıyla tahmin eden yazılım ve iş akışı düzeyinde doğrulanmış bir Klinik Karar Destek Sistemi (CDSS prototipi) başarıyla kurulmuştur. XGBoost modelleri %83 - %90 arasında doğruluk elde etmiş, SHAP ve Gemini LLM entegrasyonu ile klinik şeffaflık ve hasta iletişimde yeni bir standart yakalanmıştır.

8.2. Gelecek Çalışmalar

İlerleyen dönemde sistemin; hastanelerin Otomasyon Sistemleri (HBYS / LIS) ile entegre edilmesi, derin öğrenme (LSTM / Transformer) modelleri ile zaman serisi bazlı geçmiş tahlil trend analizi yapması ve daha geniş hasta gruplarında klinik validasyondan geçirilmesi planlanmaktadır.

KAYNAKÇA

1. American Diabetes Association (ADA). (2024). Standards of Medical Care in Diabetes—2024. *Diabetes Care*, 47(Suppl. 1), S1–S345.
2. Kidney Disease: Improving Global Outcomes (KDIGO) CKD Work Group. (2024). KDIGO 2024 Clinical Practice Guideline for the Evaluation and Management of Chronic Kidney Disease. *Kidney International*, 105(4S), S117–S314.
3. Dobiášová, M. (2004). Atherogenic Index of Plasma [log(TG/HDL-C)]: Theoretical and Practical Implications. *Clinical Chemistry*, 50(7), 1113–1115.
4. Ergün, Ö. N., & İlhan, H. O. (2021). Early Stage Diabetes Prediction Using Machine Learning Methods. *European Journal of Science and Technology*, (26), 341–348.
5. Nahzat, S., & Yağanoğlu, M. (2021). Makine Öğrenimi Sınıflandırma Algoritmalarını Kullanarak Diyabet Tahmini. *European Journal of Science and Technology*, (28), 715–722.
6. Gül, Ö., & Temurtaş, F. (2022). Kronik Böbrek Hastalığının Erken Teşhisinde Derin ve Karmaşık Sınıflandırıcıların Performans Analizi. *Bilişim Teknolojileri Dergisi*, 15(3), 289–298.
7. Bozkurt, F., & Yıldırım, M. (2020). Kardiyovasküler Hastalık Risk Tahmininde Makine Öğrenmesi Yöntemlerinin Karşılaştırmalı Analizi. *Avrupa Bilim ve Teknoloji Dergisi*, (20), 450–458.
8. Singhal, K., Azizi, S., Tu, T., Mahdavi, S. S., Wei, J., Chung, H. W., ... & Natarajan, V. (2023). Large language models encode clinical knowledge. *Nature*, 620(7972), 172–180.
9. Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS 30)*, 4765–4774.
10. Kavakiotis, I., Tsave, O., Salifoglou, A., Ntripas, N., Vlahavas, I., & Astrakas, D. (2017). Machine Learning and Data Mining Methods in Diabetes Research. *Computational and Structural Biotechnology Journal*, 15, 104–116.
11. Weng, S. F., Reps, J., Kai, J., Garibaldi, J. M., & Qureshi, N. (2017). Can Machine Learning Improve Cardiovascular Risk Prediction Using Routine Clinical Data? *PLOS ONE*, 12(4), e0174944.
12. Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

EKLER